Московский государственный технический университет им. Н.Э. Баумана
Кафедра «Системы обработки информации и управления»

Лабораторная работа №3
по дисциплине
«Методы машинного обучения»
на тему
«Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных.»

Выполнил:
студент группы ИУ5-24М
_____ Д. В. Лужевский

Москва, 2019 г.

1 Цель лабораторной работы

Изучить способы предварительной обработки данных для дальнейшего формирования моделей.

2 Задание

Требуется:

1. Выбрать набор данных (датасет), содержащий категориальные признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных.
2. Для выбранного датасета (датасетов) на основе материалов лекции решить следующие задачи:
   - обработку пропусков в данных;
   - кодирование категориальных признаков;
   - масштабирование данных.

3 Ход выполнения работы

Подключим все необходимые библиотеки и настроим отображение графиков:

```
In [3]: import numpy as np
        import pandas as pd
        import seaborn as sns
        import sklearn.impute
        import sklearn.preprocessing

        # Enable inline plots
        %matplotlib inline

        # Set plot style
        sns.set(style="ticks")

        # Set plots formats to save high resolution PNG
        from IPython.display import set_matplotlib_formats
        set_matplotlib_formats("retina")
```

Зададим ширину текстового представления данных, чтобы в дальнейшем текст в отчёте влезал на A4:

```
In [4]: pd.set_option("display.width", 70)
```

Возьмём набор данных по приложениям в Google Play Store:

```
In [5]: data = pd.read_csv("data/googleplaystore.csv")
```

Посмотрим на эти наборы данных:

```
In [9]: data.head()
```

```
Out[9]:                                                 App  \
        0     Photo Editor & Candy Camera & Grid & ScrapBook
        1                                Coloring book moana
        2  U Launcher Lite - FREE Live Cool Themes, Hide ...
        3                              Sketch - Draw & Paint
        4               Pixel Draw - Number Art Coloring Book

                 Category  Rating  Reviews  Size     Installs  Type Price  \
        0  ART_AND_DESIGN     4.1      159   19M      10,000+  Free     0
        1  ART_AND_DESIGN     3.9      967   14M     500,000+  Free     0
        2  ART_AND_DESIGN     4.7    87510  8.7M   5,000,000+  Free     0
        3  ART_AND_DESIGN     4.5   215644   25M  50,000,000+  Free     0
        4  ART_AND_DESIGN     4.3      967  2.8M     100,000+  Free     0

          Content Rating                     Genres      Last Updated  \
        0       Everyone               Art & Design   January 7, 2018
        1       Everyone  Art & Design;Pretend Play  January 15, 2018
        2       Everyone               Art & Design    August 1, 2018
        3           Teen               Art & Design      June 8, 2018
        4       Everyone    Art & Design;Creativity     June 20, 2018

                  Current Ver   Android Ver
        0               1.0.0  4.0.3 and up
        1               2.0.0  4.0.3 and up
        2               1.2.4  4.0.3 and up
        3  Varies with device    4.2 and up
        4                 1.1    4.4 and up
```

Просмотрим типы:

```
In [12]: data.dtypes
```

```
Out[12]: App               object
         Category          object
         Rating           float64
         Reviews            int64
         Size              object
         Installs          object
         Type              object
         Price             object
         Content Rating    object
         Genres            object
         Last Updated      object
         Current Ver       object
         Android Ver       object
         dtype: object
```

Кол-во строк и столбцов

```
In [14]: data.shape
```

```
Out[14]: (10841, 13)
```

3.1 Обработка пропусков в данных

Найдем все пропуски в данных:

```
In [16]: data.isnull().sum()
```

```
Out[16]: App                  0
         Category             0
         Rating            1474
         Reviews              0
         Size                 0
         Installs             0
         Type                 1
         Price                0
         Content Rating       0
         Genres               1
         Last Updated         0
         Current Ver          8
         Android Ver          2
         dtype: int64
```

Очевидно, что мы будем работать с колонкой Rating.
Самый простой вариант — заполнить пропуски нулями:

```
In [17]: sns.distplot(data["Rating"].fillna(0));
```

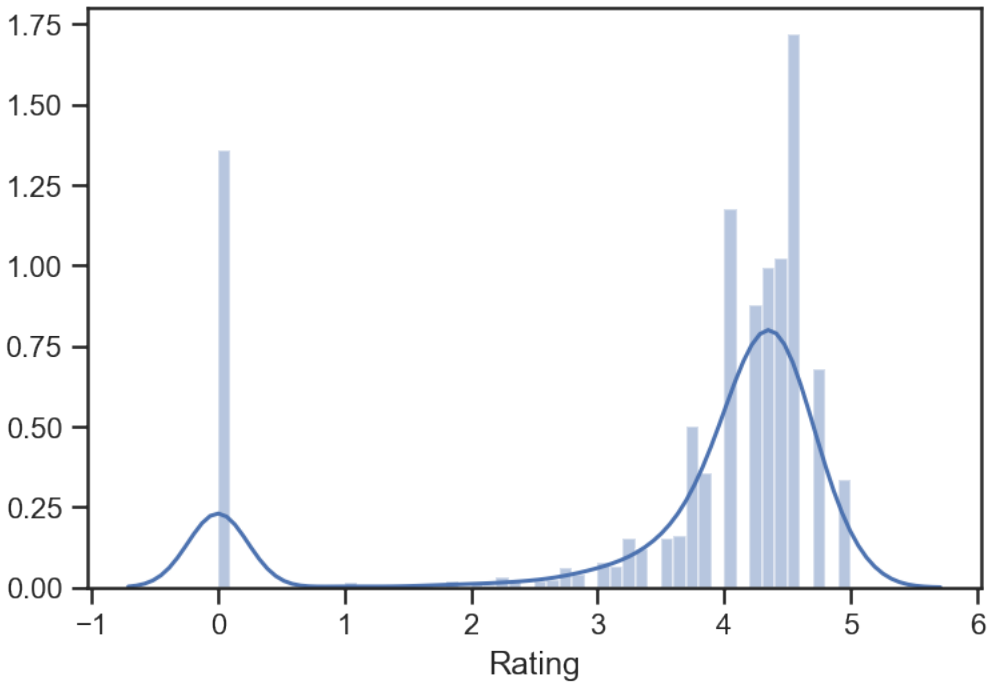

Видно, что в данной ситуации это приводит к выбросам. Логичнее было бы приложениям без рейтинга присваивать средний рейтинг:

```
In [18]: mean_imp = sklearn.impute.SimpleImputer(strategy="mean")
         mean_rat = mean_imp.fit_transform(data[["Rating"]])
         sns.distplot(mean_rat);
```

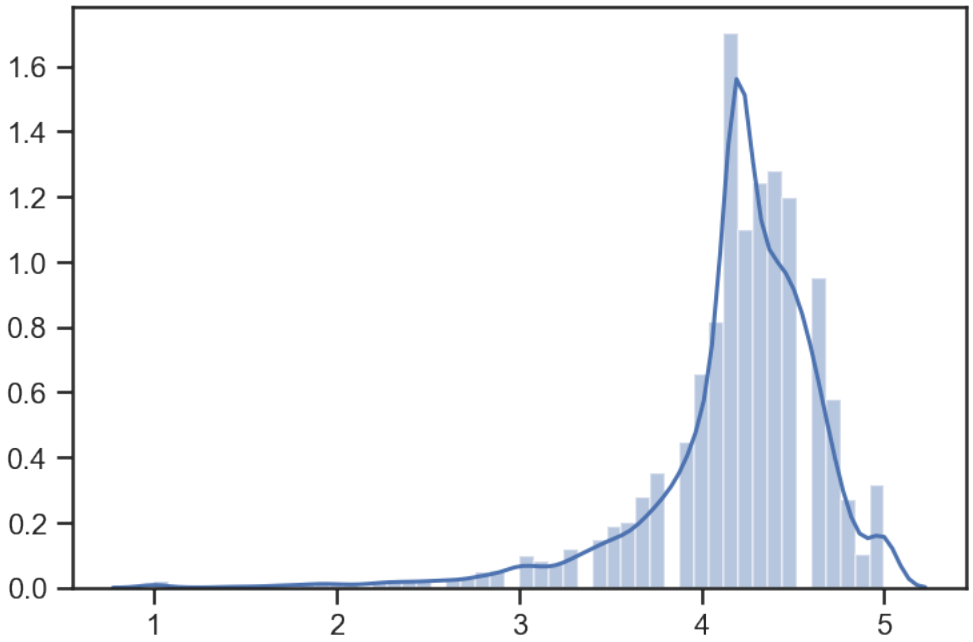

Попробуем также медианный рейтинг и самый частый рейтинг:

```
In [19]: med_imp = sklearn.impute.SimpleImputer(strategy="median")
         med_rat = med_imp.fit_transform(data[["Rating"]])
         sns.distplot(med_rat);
```

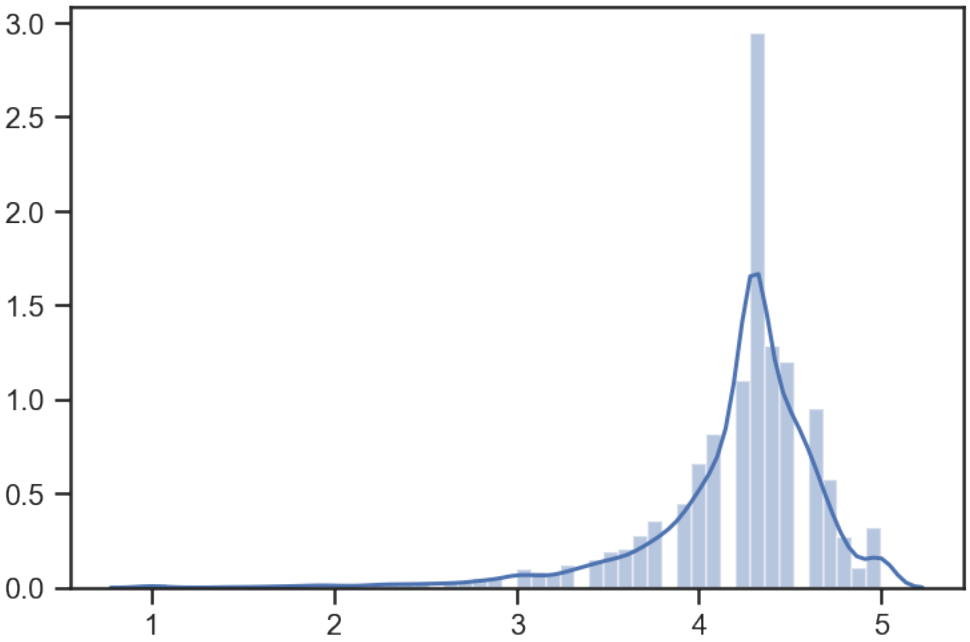

In [20]:
```
freq_imp = sklearn.impute.SimpleImputer(strategy="most_frequent")
freq_rat = freq_imp.fit_transform(data[["Rating"]])
sns.distplot(freq_rat);
```

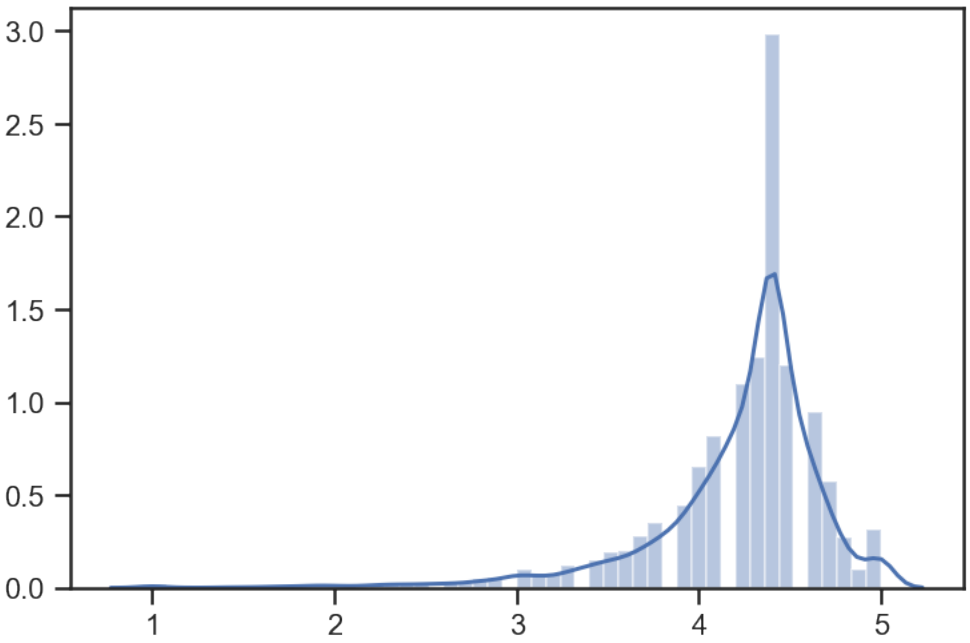

Видно, что самый близкий к нормальному распределению график дало обычное среднее значение. Остановимся на нём:

```
In [21]: data["Rating"] = mean_rat
```

3.2 Кодирование категориальных признаков

Рассмотрим колонку Type:

```
In [24]: types = data["Type"].dropna().astype(str)
         types.value_counts()
```

```
Out[24]: Free    10040
         Paid      800
         Name: Type, dtype: int64
```

Выполним кодирование категорий целочисленными значениями:

```
In [25]: le = sklearn.preprocessing.LabelEncoder()
         type_le = le.fit_transform(types)
         print(np.unique(type_le))
         le.inverse_transform(np.unique(type_le))
```

```
[0 1]


Out[25]: array(['Free', 'Paid'], dtype=object)
```

Выполним кодирование категорий наборами бинарных значений:

```
In [26]: type_oh = pd.get_dummies(types)
         type_oh.head()
```

```
Out[26]:    Free  Paid
         0     1     0
         1     1     0
         2     1     0
         3     1     0
         4     1     0
```

```
In [27]: type_oh[type_oh["Paid"] == 1].head()
```

```
Out[27]:      Free  Paid
         234     0     1
         235     0     1
         290     0     1
         291     0     1
         427     0     1
```

3.3 Масштабирование данных

Для начала попробуем обычное MinMax-масштабирование:

```
In [28]: mm = sklearn.preprocessing.MinMaxScaler()
         sns.distplot(mm.fit_transform(data[["Rating"]]));
```

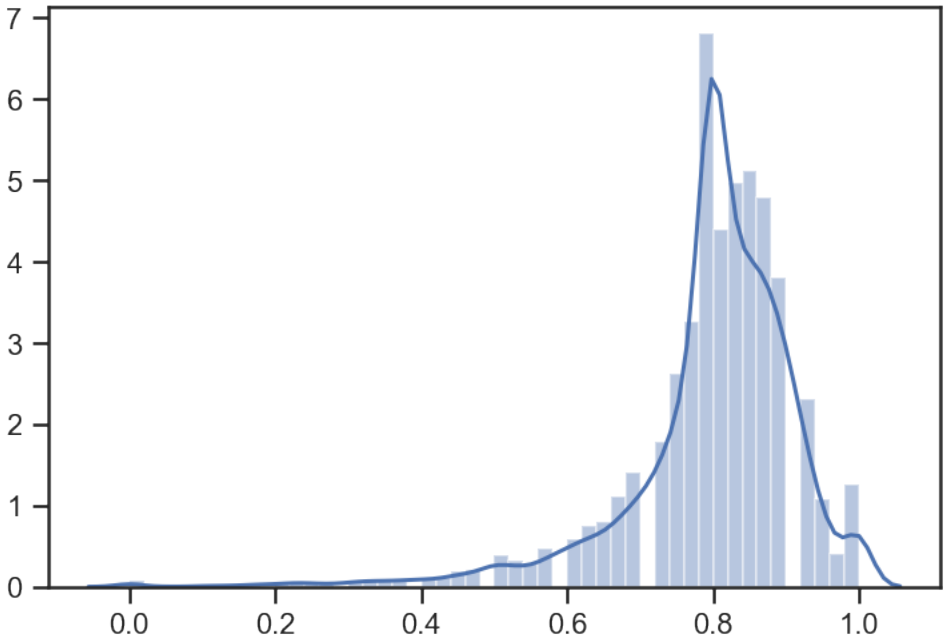

Попробуем масштабирование на основе Z-оценки:

```
In [29]: ss = sklearn.preprocessing.StandardScaler()
         sns.distplot(ss.fit_transform(data[["Rating"]]));
```

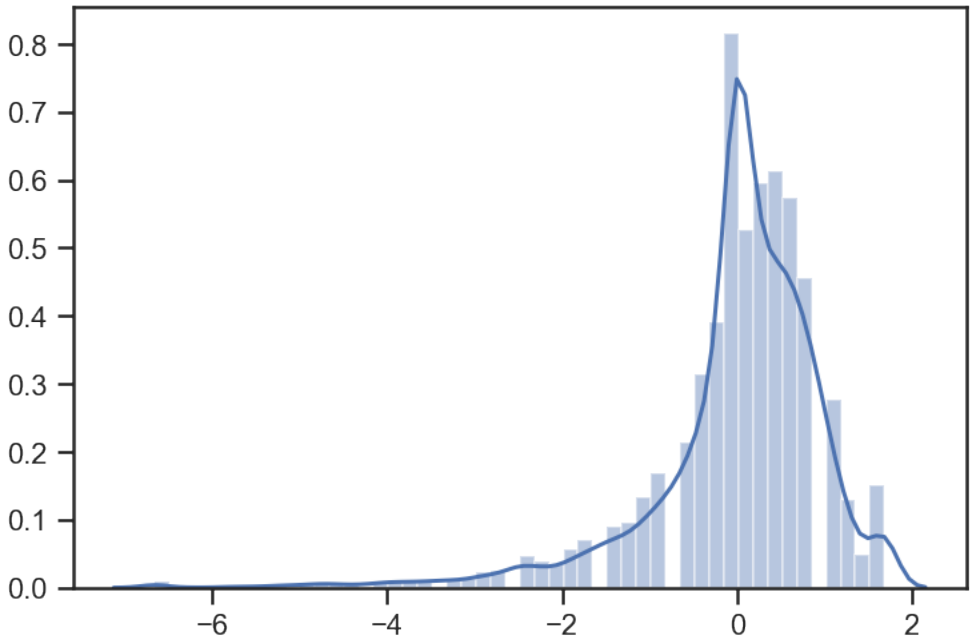
0.8
0.7
0.6
0.5
0.4
0.3
0.2
0.1
0.0
−6
−4
−2
0
2